泛癌选择性基因依赖预测与 ccRCC 候选优先排序

跨癌系泛化 · 跨平台复现 · 模型公平比较 · 患者证据边界

表达谱

细胞系 / 患者

→

选择性依赖

排除普遍必需基因

→

外部检验

CRISPR / RNAi

→

候选证据

功能与正常肾风险

核心发现：表达含有可迁移信号；复杂模型尚未稳定超过 PCR-ridge。

研究问题：从分子特征到可验证的功能假设

预测什么?

哪些基因对特定癌模型
比平均水平更重要?

能否迁移?

在未见癌系和另一扰动
平台上，排序是否仍有效?

证据到哪一步?

患者候选是否稳定?
正常肾是否存在功能风险?

功能依赖：基因受扰动后，细胞生长或存活受到影响。

研究目标是缩小功能实验范围；当前尚无患者匹配的基因扰动真值。

公开数据构成分层证据链

数据层	规模 / 角色	能够回答的问题
DepMap 24Q4	873 模型；15,835 共有基因	表达能否预测细胞系 CRISPR 依赖?
跨癌系评价	805 模型；19 癌系；780 患者组	能否泛化到训练中未见的癌系?
Sanger / DRIVE	外部 CRISPR / 独立 RNAi 技术	依赖方向能否跨扰动平台复现?
TCGA-KIRC	156 Train / 53 Validation / 51 Test	患者候选频率与表达方向是否稳定?
HPA / GTEx / 文献	正常组织暴露与直接扰动证据	候选的支持、冲突与正常肾风险?

数据层级决定结论层级：表达稳定性不能替代功能验证。

README.md：数据和评价方法；results/historical/final_evidence_synthesis_v2/

分析框架：模型比较与患者证据分别审查

A 模型评价

表达 → 依赖

训练折内预处理

→

癌系整组留出

患者重叠清除

→

强基线比较

PCR / EN / RRR / Deep

→

Sanger 复查

按冻结门槛推进

B 历史患者分析

冻结核岭模型 → TCGA 映射 → 前 20 候选冻结 → Locked Test → 分层证据整合

患者候选来自历史冻结核模型，不能改称最新 PCR 或 DeepDEP 的候选。

依赖残差：区分普遍必需与相对选择性

概念示意；下方矩阵不代表任何实际基因或样本。

$$r(i,j) = y(i,j) - \text{mean_train}(j)$$

每个外层训练折单独计算基因均值；更负的残差表示更强的相对依赖。

普遍强依赖



谱系选择性



低依赖

主评价排除 release-wide common-essential；该注释未在每折内部重新估计。

残差反映相对依赖；残差低不自动意味着患者特异性或安全治疗窗。

整癌系留出与嵌套选择限制信息泄漏

18 个癌系：外层训练



1 个癌系：外层评估

训练内部：5 个癌系折选择超参数 / epoch

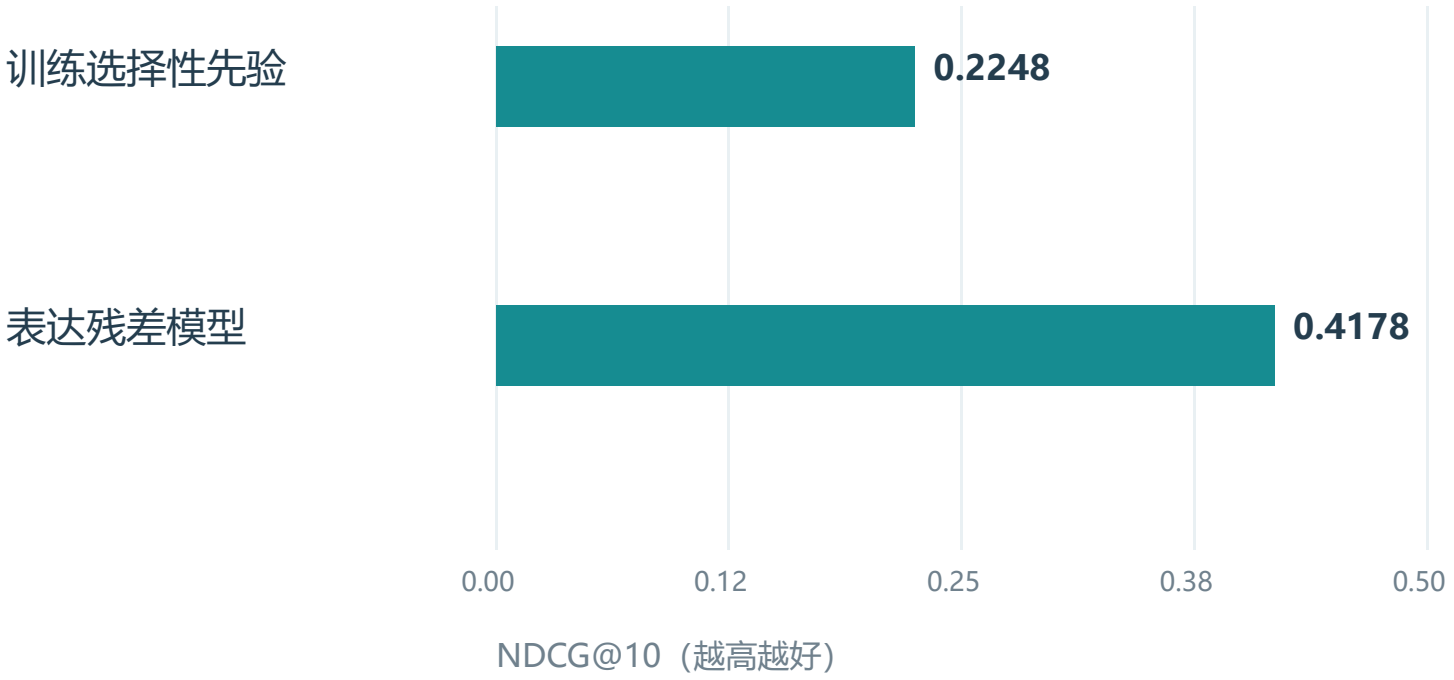
训练内 PCA、标准化与残差均值；排除患者重叠

最终比较

19 癌系等权 + 配对 bootstrap

最新模型比较属于开发期分析；不能称为未触碰的外部 Locked Test。

表达携带稳定的选择性依赖排序信息



+0.1930

癌系等权 ΔNDCG

19 / 19

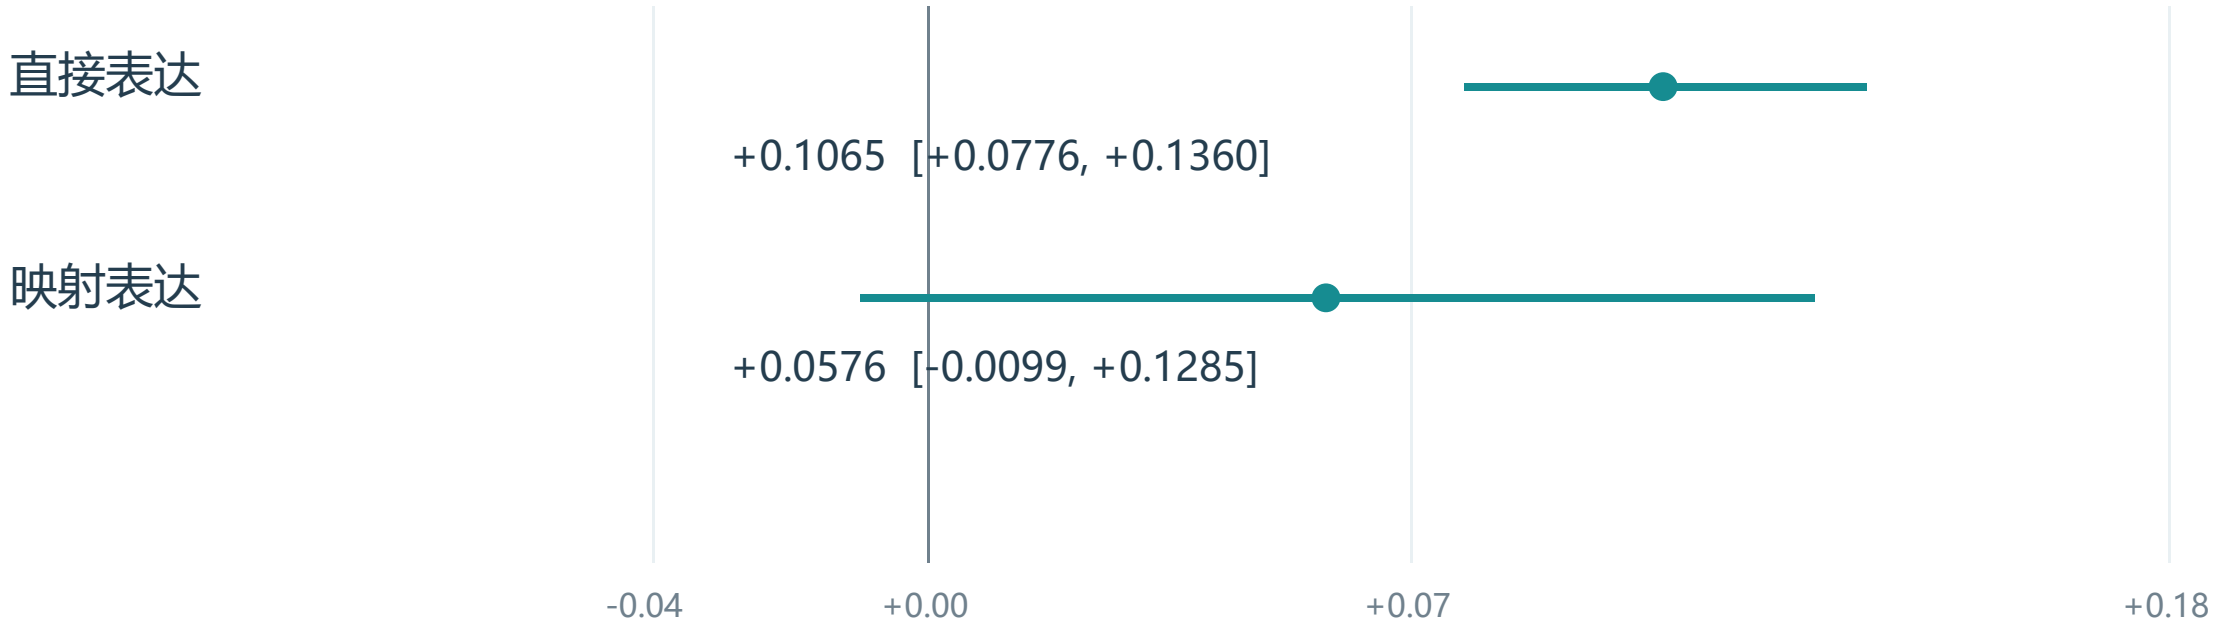
癌系增益方向为正

支持表达具有可迁移的排序信息；12 个 ccRCC 模型不足以证明额外亚型优势。

outputs/selective_dependency_lolo_v1/；outputs/selective_dependency_analysis_v1/

跨平台复现为正，但具体基因名单准确率有限

历史冻结流程：直接表达 66 模型；映射表达 17 模型。



ΔNDCG 相对训练标准化先验；95% bootstrap 区间

直接表达绝对 NDCG = 0.1670，真实 Top-10 重叠 = 0.0303；增益不等于高准确率。

公平比较必须固定输入、靶点与评价口径

相同输入

同一表达矩阵
同一模型 / 患者划分

相同目标

1,204 个映射靶点
主评价 911 个非普遍必需基因

相同主终点

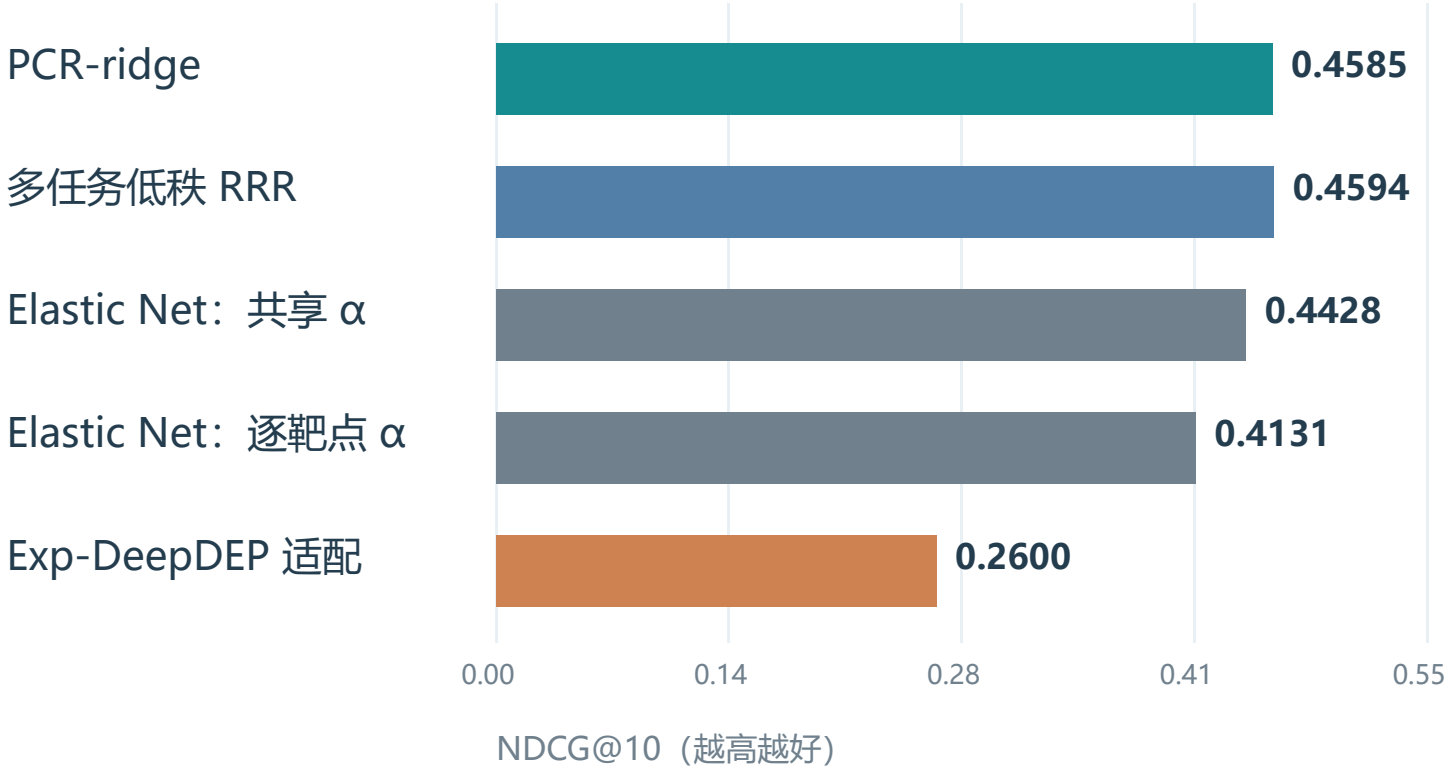
癌系等权 NDCG@10
训练内调参 + 配对区间

历史广基因空间、受限靶点空间、恢复表达后的比较：分别报告。

不能把不同基因空间、不同外部校准或不同聚合权重的分数混成一个排行榜。

增加模型复杂度没有带来稳定的主终点增益

首次受限靶点比较：911 个非 common-essential 基因；19 癌系等权。



RRR − PCR

+0.0009

95% CI
[−0.0043, +0.0060]

RRR 的点估计接近 PCR；区间跨 0，不支持主排序指标稳定获益。

results/historical/advanced_model_benchmark_v1/overall_summary.csv；bootstrap.csv

数值审计排除了部分优化精度解释

实验	NDCG@10	解释
PCR-ridge	0.4585	同一受限靶点基准
原 Elastic Net	0.4428	原共享 α 拟合
严格数值精化	0.4405	精化后未追平 PCR
扩大 α 上界	0.4405	19/19 癌系仍选择 α = 0.1

上界网格 0.1 / 0.2 / 0.5 / 1.0；480,396 次靶点拟合通过数值认证。

结论仅覆盖已审计配置；更小 α 的完整选择过程及其他 l1_ratio 尚未穷尽。

results/historical/elastic_net_numerical_audit_v1/；elastic_net_upper_grid_v1/

恢复表达特征后重新配对比较 PCR 与 DeepDEP



两类模型共享恢复后的输入；仍有 632 个位置需要填补，不能称完整原论文复现。

两条模型路径使用同一恢复表达输入

Exp-DeepDEP 为表达适配实现；架构示意不表示各层尺寸比例。

PCR-ridge

表达
6,016 位置

→

训练内 PCA
rank 32–256

→

Ridge
α 100–100,000

→

依赖残差
多靶点输出

Exp-DeepDEP

表达编码器 6016 → 500 → 200 → 50

基因指纹编码器 3115 → 1000 → 100 → 50

→

拼接 → 依赖预测
100 → 250 → 250 → 1

500 cell–target pairs / batch

DeepDEP 使用既有非 KIRC 肿瘤预训练；主分析为残差目标，绝对依赖为次分析。

训练成本来自嵌套折、随机种子与成对批次

19

外层留出癌系

→

5 × 3 × 2

内层折 × 种子 × 目标

→

570

内层拟合，各 100 epoch

→

+ 114

外层最终重拟合

684

完成拟合数

61,710

累计 epoch 数

≈ 49.9 h

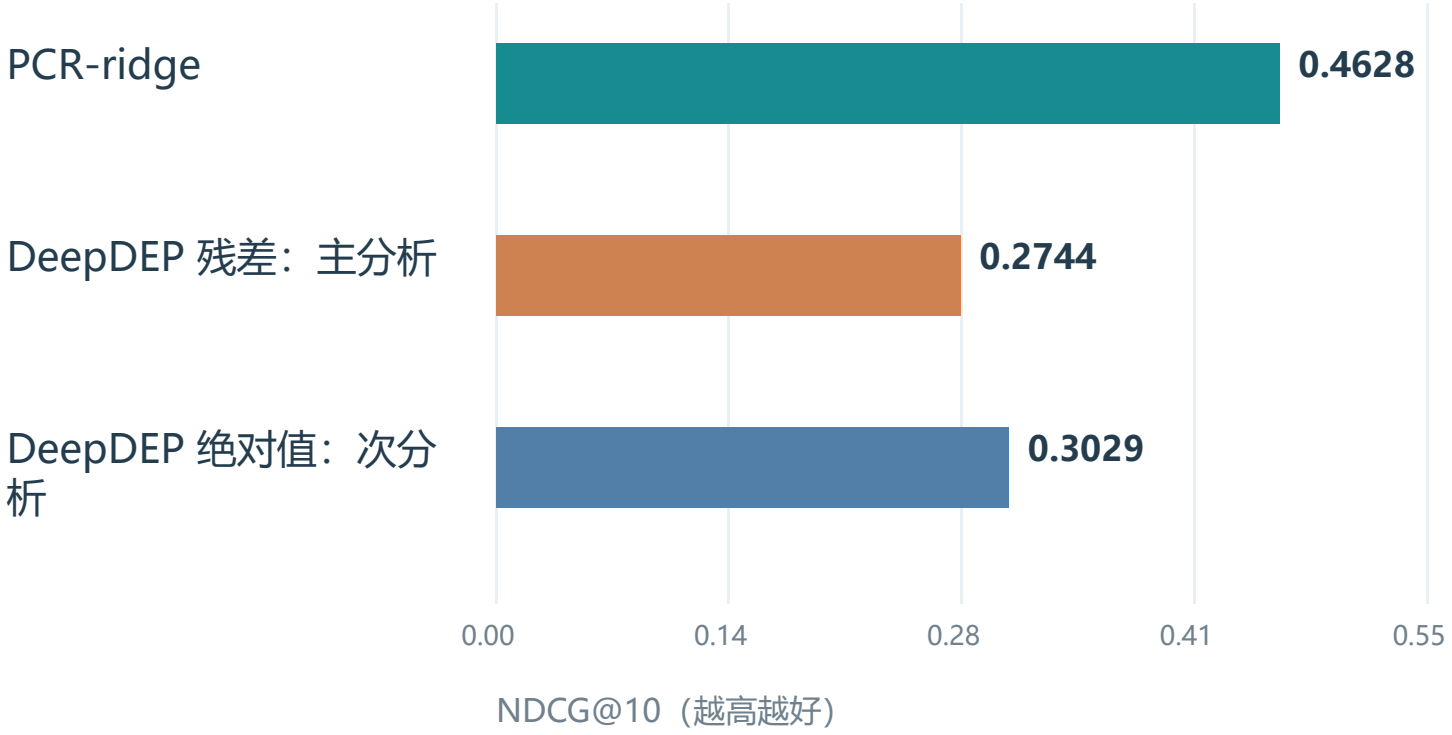
记录的 epoch 耗时之和

49.9 h 不是总墙钟时间，也不是纯 GPU 利用时长；不能据此比较所有模型总成本。

results/historical/deepdep_recovered_comparison_v1/training.csv.gz；run.json

恢复表达后，PCR 仍明显优于两种 DeepDEP 目标

19 癌系等权；805 模型；911 个非 common-essential 靶点。



0.4628

PCR NDCG@10

0.4066

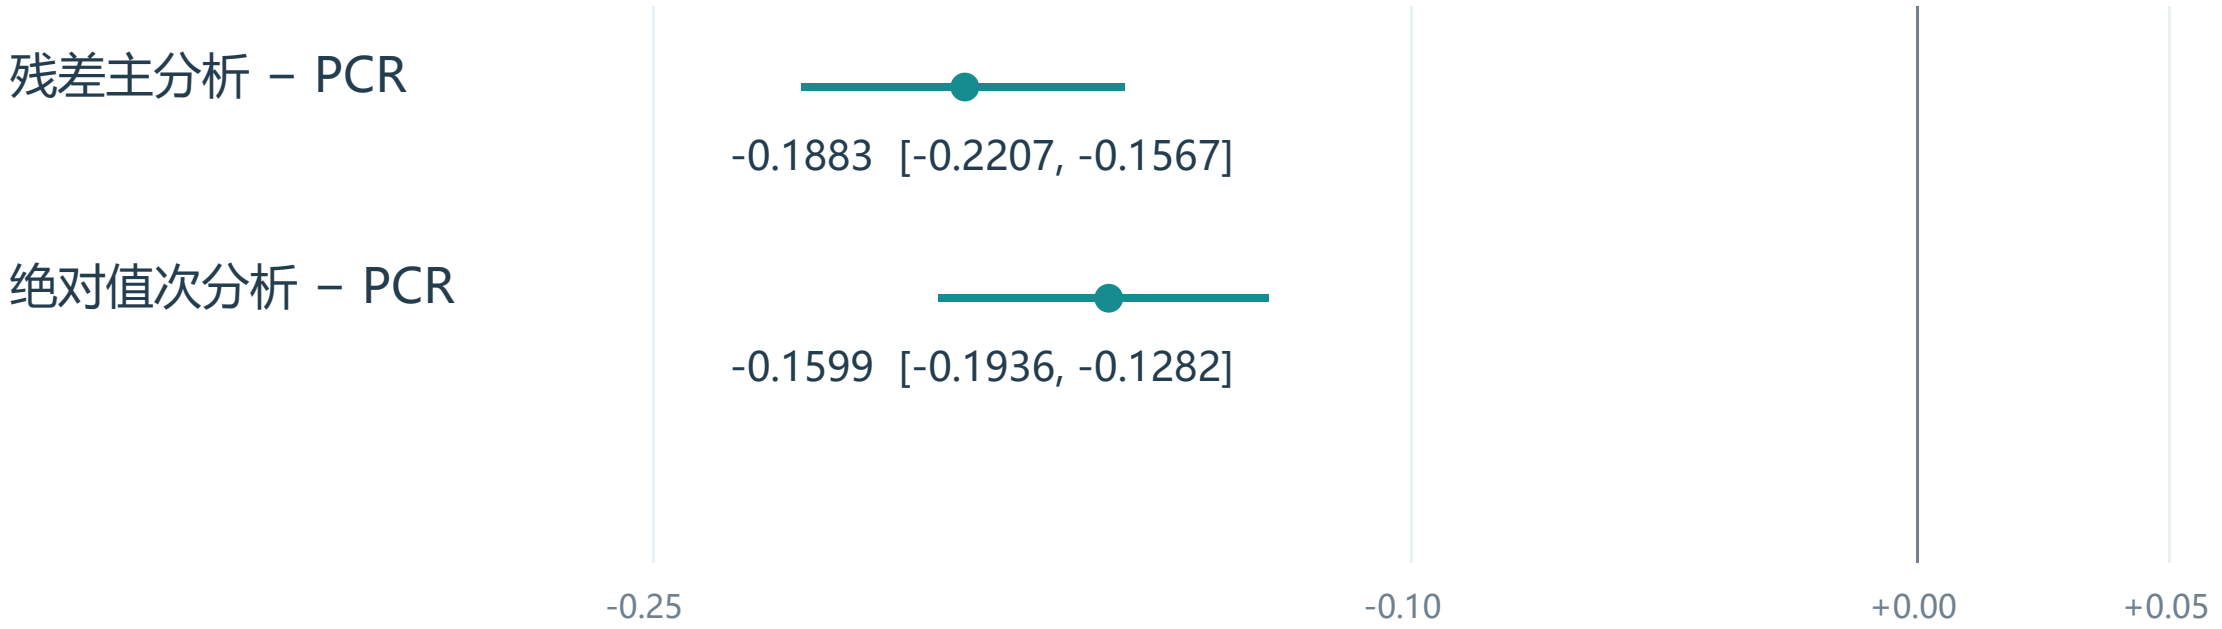
PCR 选择性命中率@10

在当前数据、训练协议和评价目标下，没有证据支持用 DeepDEP 替换 PCR。

results/historical/deepdep_recovered_comparison_v1/overall_summary.csv

配对区间与逐癌系方向一致支持 PCR

差值 = DeepDEP − PCR；按癌系等权 bootstrap，n = 19。



两种 DeepDEP 目标均在 19/19 个癌系低于 PCR；该结果不能外推为所有深度学习无效。

results/historical/deepdep_recovered_comparison_v1/bootstrap.csv；lineage_summary.csv

癌系异质性存在，但未出现 DeepDEP 优势癌系

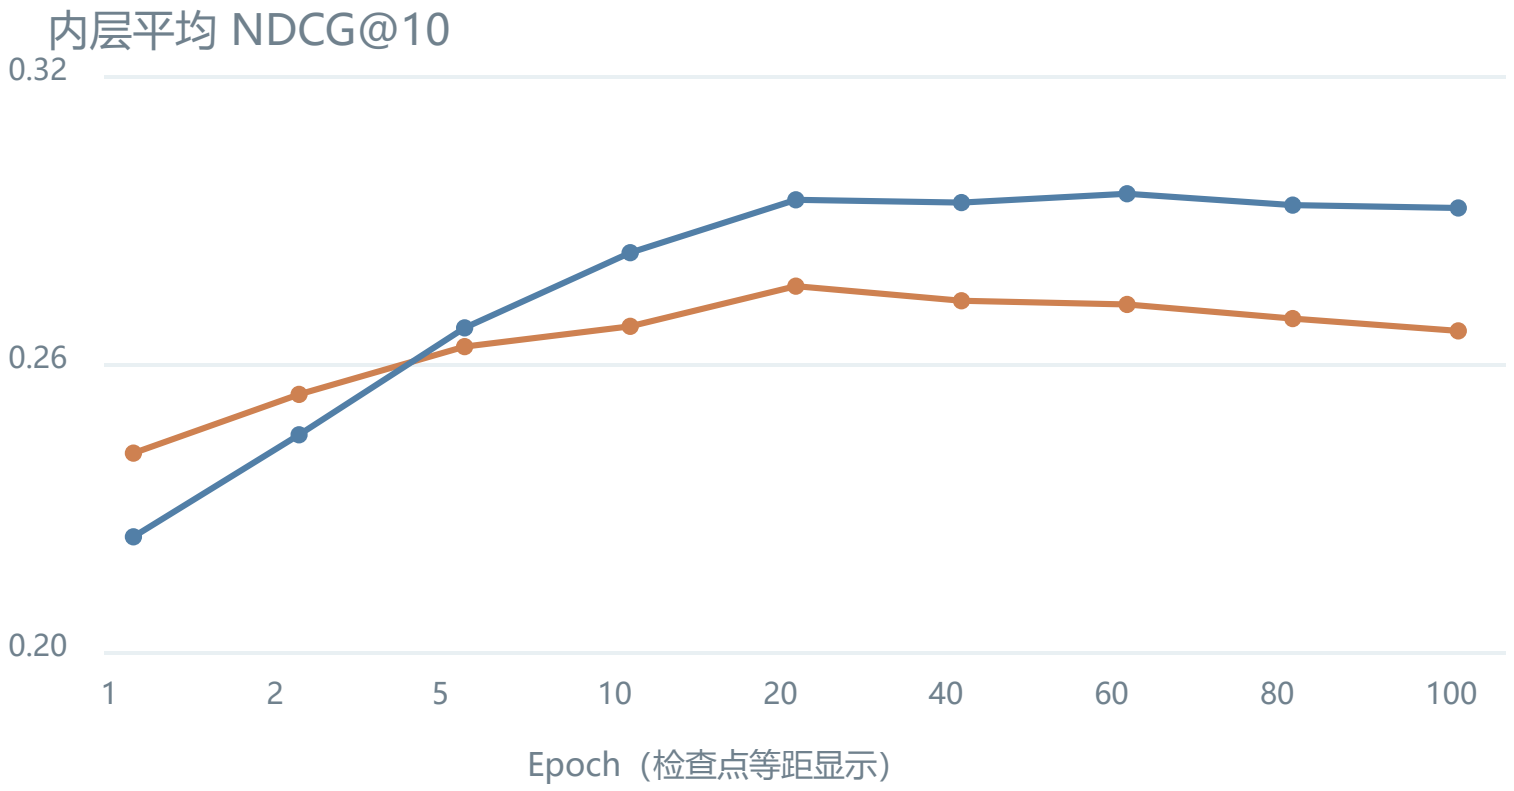
每行一个留出癌系；颜色与数值均表示 NDCG@10，不显示独立误差区间。

癌系	PCR	Deep 残差	Deep 绝对	癌系	PCR	Deep 残差	Deep 绝对
Biliary Tract	0.515	0.263	0.344	Lung	0.392	0.217	0.240
Bladder/Urinary Tract	0.445	0.323	0.381	Lymphoid	0.455	0.386	0.383
Bone	0.363	0.267	0.318	Myeloid	0.494	0.291	0.319
Bowel	0.495	0.228	0.335	Ovary	0.472	0.268	0.269
Breast	0.430	0.254	0.251	Pancreas	0.536	0.262	0.331
CNS/Brain	0.417	0.343	0.333	PNS	0.364	0.183	0.247
Esophagus	0.456	0.291	0.290	Skin	0.603	0.244	0.248
Head / Neck	0.456	0.273	0.368	Soft Tissue	0.398	0.231	0.272
Kidney	0.566	0.324	0.307	Uterus	0.440	0.212	0.231
Liver	0.495	0.355	0.290				

Kidney：PCR 0.5661，Deep 残差 0.3238，Deep 绝对值 0.3070；Kidney 不等同于 ccRCC。

延长同类训练缺乏明确收益依据

曲线是重叠训练任务的描述性汇总；不能当作独立样本推断，亦未据此重新选 epoch。



残差目标

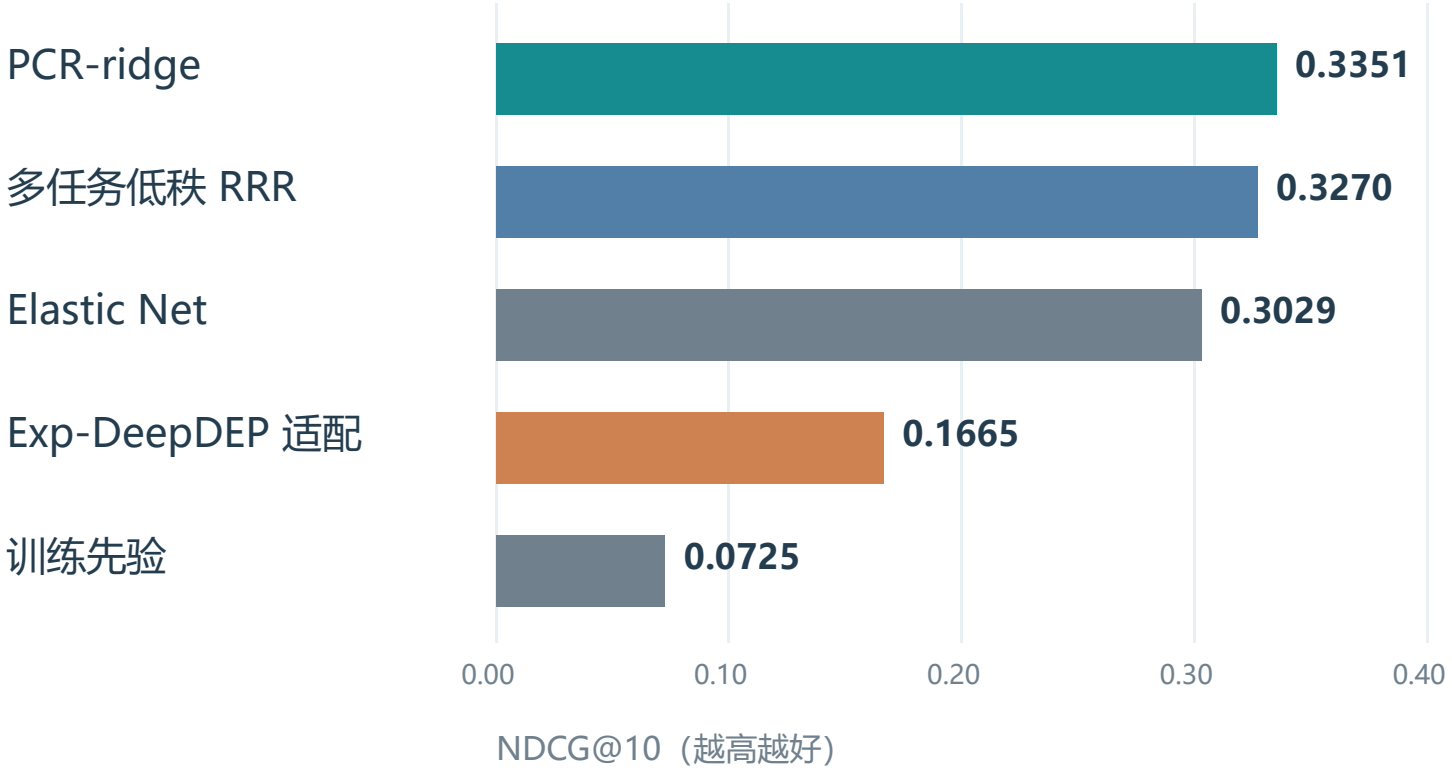
绝对值目标

性能未随 epoch 持续上升

当前证据支持停止追加同类训练；输入恢复与批次修复的各自因果贡献尚未分离。

受限靶点的 Sanger 外部比较同样未支持复杂模型

历史高级模型外部比较：64 模型 / 13 癌系 / 871 共同评价基因；不是最新 DeepDEP 的外部结果。



RRR − PCR

−0.0082

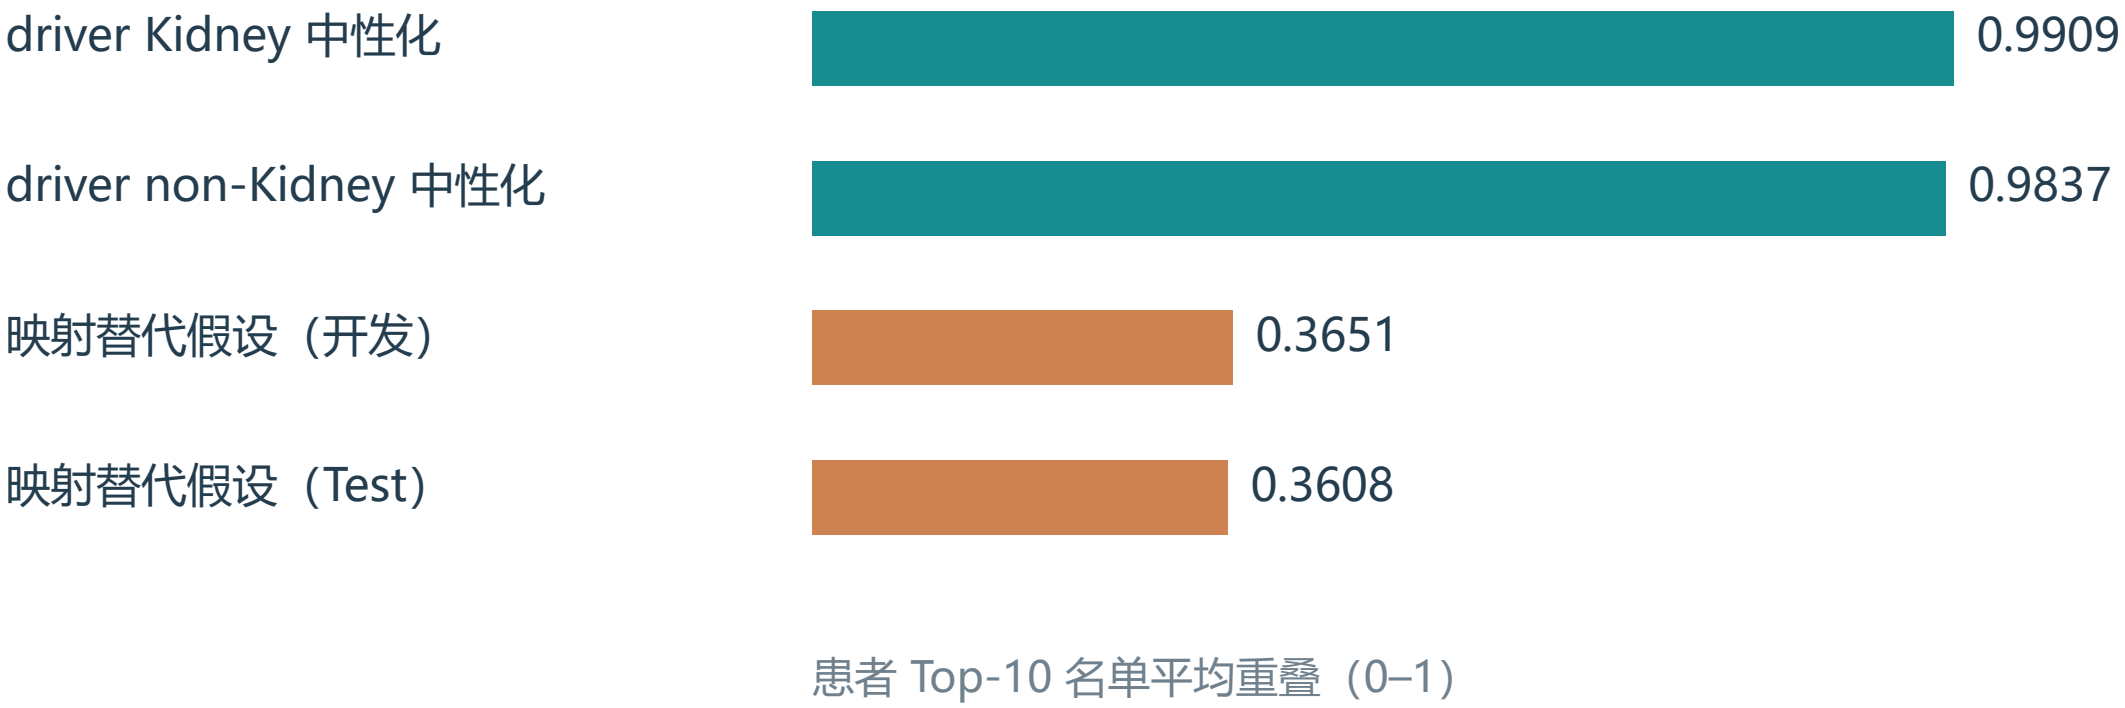
95% CI
[−0.0336, +0.0159]

最新恢复表达 DeepDEP 未通过内部推进门槛，因此没有新一轮 Sanger 验证。

results/historical/sanger_advanced_benchmark_v1/；README.md：阶段十

患者域：队列稳定性与映射敏感性同时存在

本节均来自历史冻结核模型；患者无功能依赖标签。



表达映射是重要不确定性：合理映射之间仅约 36% 的头部候选相同。

Locked Test 确认了稳定性，没有确认患者功能

冻结协议

模型 / 映射 / 候选 / 指标

→

一次正式访问

51 个患者

→

频率稳定性

前 20：ρ = 0.7984

→

配对表达方向

14 对肿瘤 / 正常

区间支持预设表达方向

PAX8 · FERMT2 · CCND1

方向相同，但区间跨 0

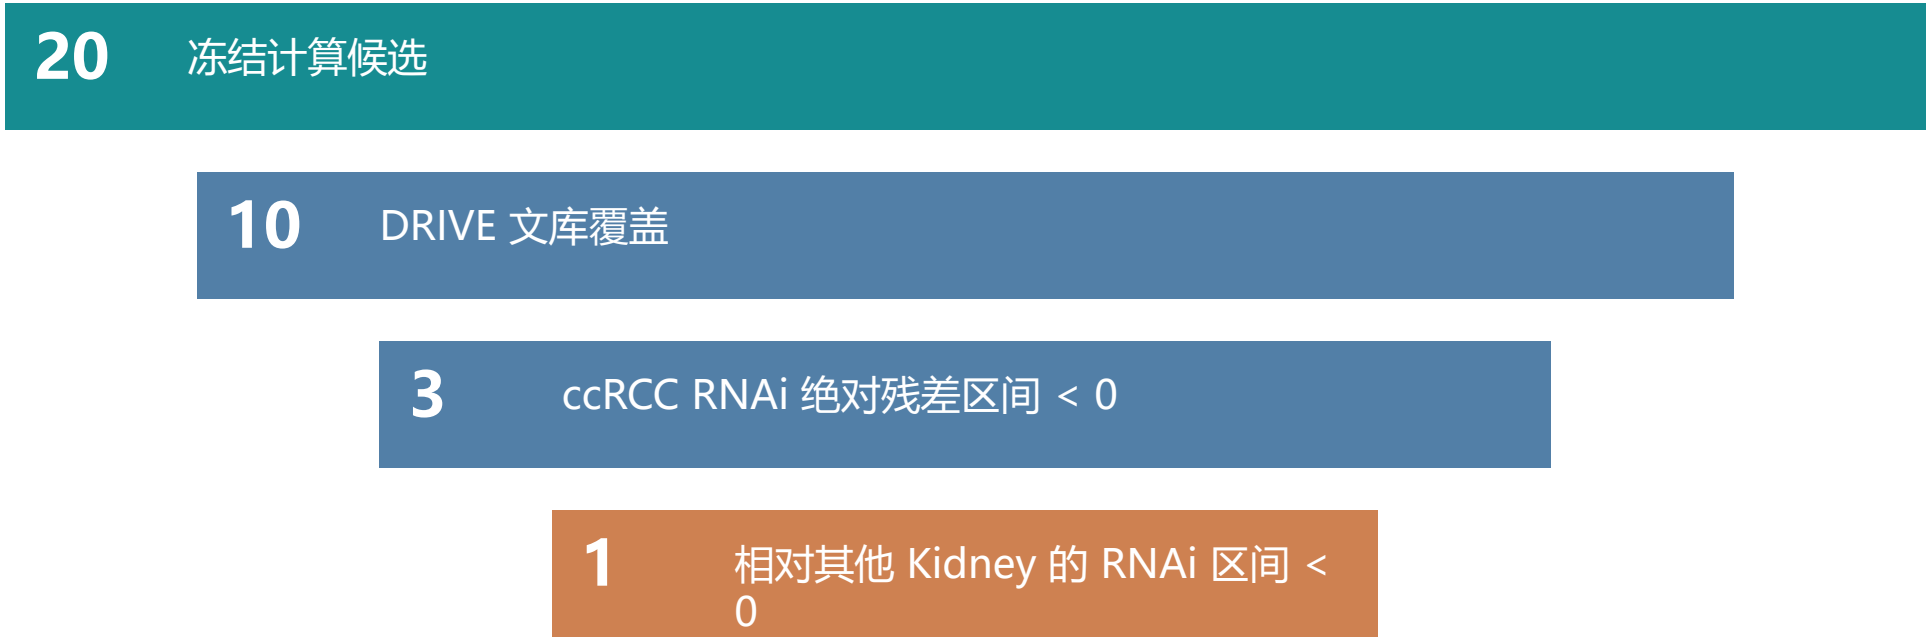
HNF1B：尚未确认

Test 已被正式访问；不能再充当新 PCR 或新 DeepDEP 的独立确认集。

results/historical/tcga_locked_test_v1/；冻结提交 73f9972

证据逐层收窄：计算候选不等同于治疗靶点

患者来源资源结论限于 2026 年 9 月冻结审计范围，并非声称全球不存在相关数据。



0 个候选获得该审计范围内的患者来源功能真值确认

DRIVE 是独立扰动技术，部分细胞系重叠；不能称为独立患者队列验证。

主要候选的功能支持与风险并存

强调证据层次；候选展示顺序用于讨论，未改变冻结 discovery rank。

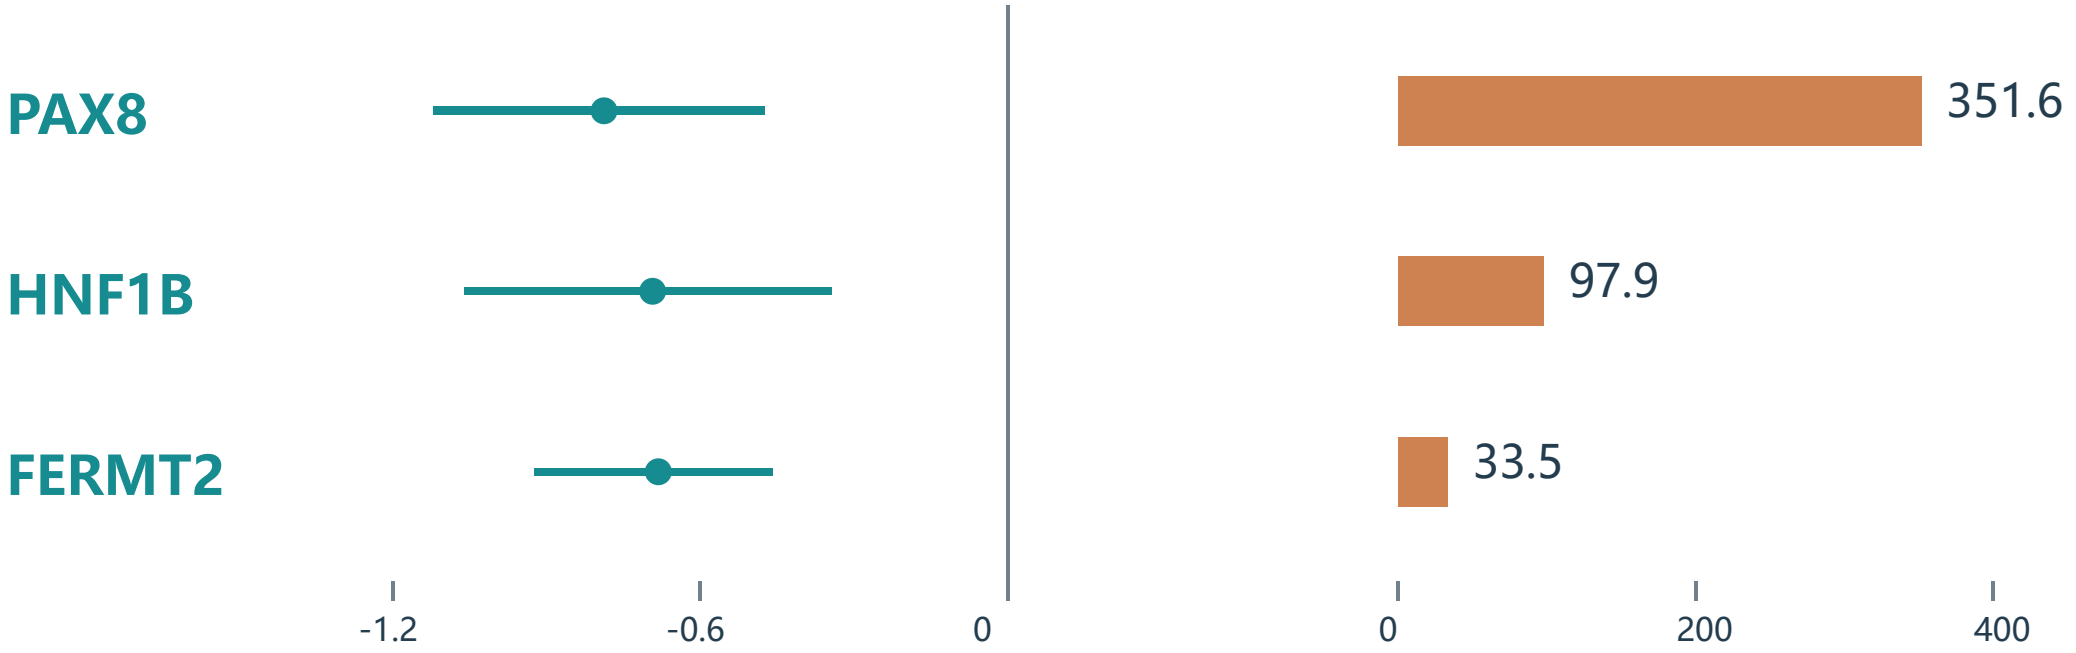
候选	RNAi 依赖	相对 Kidney	直接文献	正常肾风险
PAX8	支持	支持	支持	表达 + 类器官
HNF1B	支持	区间跨 0	非同行评议	表达 + 类器官
FERMT2	支持	未建立	证据缺口	表达暴露
CCND1	区间跨 0	未建立	支持	治疗窗未知
YPEL5	未形成支持	未建立	反向证据	非优先抑制靶点

PAX8 证据最一致，但没有证明治疗窗；YPEL5 存在与优先抑制方向冲突的证据。

results/historical/final_evidence_synthesis_v2/candidate_evidence_matrix.csv

正交 RNAi 支持不能消除正常肾暴露问题

左：DRIVE ccRCC 平均依赖残差与 bootstrap 区间；右：GTEx 肾组织最高中位 TPM。



正常肾类器官发育扰动提示风险；不能直接换算为成人肾毒性或临床安全窗。

与既有工作的区别在评价问题与证据审计

文献差异不是性能优越性的证据；当前适配实现并非原论文逐项复现。

维度	TCGA-DEPMAP / DeepDEP	本项目
核心目标	泛癌依赖预测与患者转化	选择性依赖排序与 ccRCC 候选审计
当前侧重	患者关联、转化资源与实验支持	整癌系留出、强基线、数值与输入审计
患者证据	各自设计的临床关联 / 实验验证	冻结 Test 的表达与频率稳定性
结论边界	不同数据与评价协议	不能用本项目分数宣称超过原论文

合理定位：可审查的预测与证据流程；创新性不能仅由模型复杂度或候选名称支持。

Shi et al. Nature Cancer (2024), doi:10.1038/s43018-024-00789-y；DeepDEP (2021), PMC8378822

当前主要限制及下一阶段的决策门槛

方法层面

统一比较表与逐癌系图
独立环境完整复跑
保留 PCR 作为强基线

患者迁移

单独冻结新模型协议
报告映射敏感性
另寻未使用确认数据

功能与安全

患者来源模型扰动
正常肾平行扰动
剂量与可比生长终点

公开数据阶段的主要瓶颈：功能真值缺失、少量 ccRCC 模型、细胞系到患者的域差异。

若目标升级为治疗靶点结论，必须补充新的功能证据；继续同类训练不能填补这一缺口。

结论：表达可预测，复杂度不保证收益，患者证据仍有限

01 **方法结论**

表达支持可迁移的细胞系选择性依赖排序。

02 **模型结论**

同数据严格比较未发现复杂模型稳定超过 PCR。

03 **生物学结论**

获得分层候选与风险线索，尚未证明患者功能依赖或治疗窗。

项目成果是可追溯的候选优先排序与证据边界，不是已验证的临床靶点。

数据与结果来源

DepMap 24Q4	doi:10.25452/figshare.plus.27993248.v1
TCGA-DEPMAP	Shi et al. Building a translational cancer dependency map for The Cancer Genome Atlas. Nature Cancer 5, 1176–1194 (2024). doi:10.1038/s43018-024-00789-y
DeepDEP	2021 原文：pmc.ncbi.nlm.nih.gov/articles/PMC8378822/ 官方实现：github.com/chenlab-gccri/DeepDEP
正式模型结果	results/historical/deepdep_recovered_comparison_v1/ advanced_model_benchmark_v1/；sanger_advanced_benchmark_v1/
候选与患者证据	results/historical/final_evidence_synthesis_v2/；tcga_locked_test_v1/ 完整溯源见各页备注和项目 README。